

Memoria del Trabajo Final de Máster: Análisis de la participación en carreras populares en España

Clàudia Rafart Medina

Data Analytics - ThePower Education

30 de septiembre de 2026

Resumen

Este Trabajo de Fin de Máster analiza la participación en carreras populares en España: running, ciclismo, natación, marcha y modalidades multideporte como el triatlón. El objetivo es entender cómo se distribuye la participación por geografía, por fecha y por género, y estimar cuántos finishers puede tener una carrera a partir de sus características. Para ello se construye un dataset propio mediante scraping de varios portales de cronometraje online, que se limpia, unifica y depura de valores atípicos. El análisis exploratorio muestra que el historial propio de cada carrera es la señal que mejor ayuda a anticipar su tamaño, por delante de otras variables como la población del municipio, la distancia o la provincia. A partir de estos hallazgos se entrenan dos modelos (Random Forest), uno por género, que estiman el número de finishers de carreras de running y trail para público general, con mejores resultados cuando la carrera ya tiene ediciones anteriores que cuando no, que es precisamente el caso que motivó este trabajo. Los resultados del análisis y del modelo se muestran en un dashboard interactivo en Power BI. El trabajo termina señalando sus principales limitaciones, sobre todo la cobertura geográfica desigual de las fuentes y que el modelo solo cubre running y trail, y propone posibles líneas de mejora.

Palabras clave: carreras populares, running, análisis de datos, machine learning, Random Forest, Power BI, dashboard.

Abstract

This Master's Thesis analyzes participation in popular races in Spain: running, cycling, swimming, race walking and multi-sport formats such as triathlon. The aim is to understand how participation is distributed by geography, by date and by gender, and to estimate how many finishers a race can expect based on its characteristics. A custom dataset is built by scraping several online timing platforms, then cleaned, unified and checked for outliers. The exploratory analysis shows that a race's own history is the best signal for anticipating its size, ahead of other variables such as the municipality's population, the distance or the province. Building on these findings, two models (Random Forest) are trained, one per gender, to estimate the number of finishers of running and trail races for the general public category, performing better when the race already has previous editions than when it doesn't, which is precisely the use case that motivated this work. The analysis and model results are shown in an interactive Power BI dashboard. The work ends by outlining its main limitations, above all the uneven geographic coverage

of the sources and that the model only covers running and trail, and suggests possible lines of future improvement.

Keywords: popular races, running, data analysis, machine learning, Random Forest, Power BI, dashboard.

Índice

Resumen.....	i
Abstract.....	i
1. Introducción.....	1
1.1. Motivación y objetivos.....	1
1.2. Contexto de las carreras populares en España.....	1
1.3. Fuentes de datos y alcance del trabajo.....	2
1.4. Flujo de trabajo.....	2
2. Datos y metodología.....	3
2.1. Obtención de datos.....	4
2.2. Limpieza y unificación de datos.....	5
2.3. Decisiones metodológicas clave.....	7
2.4. Estructura final del dataset.....	8
3. Análisis exploratorio (EDA).....	9
3.1. Distribución geográfica.....	10
3.2. Evolución temporal.....	10
3.3. Participación por género.....	11
3.4. Modalidades y perfil de participantes.....	13
4. Modelado predictivo.....	16
4.1. Planteamiento y variables.....	16
4.2. Algoritmos y evaluación.....	17
4.3. Resultados.....	18

4.4. Limitaciones.....	22
5. Dashboard (Power BI).....	23
5.1. Modelo de datos.....	23
5.2. Recorrido por las páginas.....	23
5.3. Dificultades encontradas en el proceso.....	27
6. Conclusiones.....	27
6.1. Principales hallazgos.....	27
6.2. Limitaciones del trabajo.....	28
6.3. Líneas futuras.....	28
Declaración sobre el uso de inteligencia artificial.....	29
Bibliografía y fuentes.....	29

1. Introducción

1.1. Motivación y objetivos

Desde diciembre de 2025 trabajo en el departamento de análisis de negocio de una empresa, y me apetecía plantear este TFM como una oportunidad de hacer un análisis distinto al de mi día a día. Como runner, y viendo desde dentro el auge reciente de esta actividad, quería aprovechar este TFM para analizar el tema con datos, viendo qué dicen las estadísticas de las carreras populares en España y, en particular, saciando mi curiosidad por saber hasta qué punto los hombres siguen monopolizando las modalidades y distancias más exigentes.

A esto se suma un motivo muy concreto. Con un grupo de amigas de toda la vida que también corren, tenemos una ruta que nos gusta especialmente, y más de una vez hemos hablado de organizar algún día una carrera por allí. Esa conversación, repetida varias veces, es el origen real del modelo predictivo de este trabajo. Si algún día llegamos a organizarla, sería muy útil poder estimar de antemano cuántos corredores se apuntarían a partir de las características de la prueba. De ahí nació el interés por el modelo que se desarrolla en el [apartado 4](#).

El objetivo general de este TFM es analizar la participación en carreras populares en España (running, ciclismo, natación, triatlón y marcha) a partir de datos recogidos de distintos portales de cronometraje. De este objetivo general se derivan tres objetivos específicos:

1. Realizar un análisis exploratorio (EDA) que describa cómo se distribuye la participación por geografía, en el tiempo, por género y por modalidad deportiva, prestando especial atención a si la participación femenina disminuye en las modalidades y distancias más exigentes.
2. Construir dos modelos predictivos, uno para hombres y otro para mujeres, que estimen el número de finishers de una carrera a partir de sus características.
3. Diseñar un dashboard interactivo en Power BI que permita explorar la distribución geográfica y temporal de la participación, así como analizar por tipo de carrera y distancia y, por supuesto, su evolución por género.

1.2. Contexto de las carreras populares en España

En los últimos años, las carreras populares, tanto de running como de ciclismo, natación o triatlón, han ganado protagonismo en España, con un calendario de pruebas que cubre todo el territorio y todos los niveles, desde carreras de pueblo hasta grandes maratones y marchas cicloturistas. Esta actividad

genera, edición tras edición, una cantidad considerable de datos: número de participantes, tiempos, categorías, ubicación de la prueba, etc.

Sin embargo, estos datos no existen en un único lugar. Se publican en portales de cronometraje independientes (RaceResult, Kronoak, Timingsys, entre otros), cada uno con su propio formato y sin ningún tipo de estandarización entre ellos. Esta fragmentación es, precisamente, uno de los puntos de partida de este trabajo. Antes de poder analizar la participación a nivel nacional, hace falta reunir y homogeneizar información que nace dispersa.

1.3. Fuentes de datos y alcance del trabajo

Los datos proceden de varios portales de cronometraje online, obtenidos mediante scraping (el proceso se detalla en el [apartado 2.1](#)); algunos de ámbito nacional y otros centrados en comunidades concretas, como Cataluña o Galicia. Esto genera cierto desequilibrio en el dataset. Unas zonas del país y unas modalidades (el running, sobre todo) quedan mejor representadas que otras, simplemente por la cobertura de las fuentes disponibles.

En cuanto al periodo temporal, el trabajo se apoya en una serie histórica de varios años. El dashboard de Power BI recoge datos de 2015 a 2026, y el modelo predictivo del [apartado 4](#) entrena con los años hasta 2023 y evalúa con 2024 y 2025, dejando fuera 2026 por ser el año en curso y tener datos todavía incompletos.


El alcance de este trabajo son las carreras populares, entendidas como pruebas abiertas al público en general. Dentro de ellas también aparecen categorías de participantes de élite o profesionales, identificadas como tales en los propios datos (campo publico), sin que se hayan excluido del conjunto general. Geográficamente cubre toda España, aunque, como se ha comentado, con una representación desigual entre territorios y modalidades; no se incluyen carreras celebradas fuera del país. Las características numéricas exactas del dataset final (número de filas, columnas y niveles de cobertura) se detallan en el [apartado 2.4](#), una vez descritas las decisiones de limpieza que las determinan.

1.4. Flujo de trabajo

Todas las fuentes siguen el mismo patrón de nomenclatura de principio a fin. Cada notebook `scrape_<fuente>.ipynb` genera un `DF_<FUENTE>_SUCIO` con los datos brutos, que el notebook `Limpieza_<fuente>.ipynb` correspondiente transforma en `DF_<FUENTE>_LIMPIO`, ya adaptado al esquema común de 12 columnas. Un notebook de unión reúne los trece `DF_<FUENTE>_LIMPIO` en un

único `DF_TODAS`, y un último notebook de tratamiento de outliers produce la versión final, `DF_TODAS_SIN_OUTLIERS.csv`. A partir de este dataset final, el trabajo se ramifica en tres líneas que se desarrollan en paralelo: el análisis exploratorio, en `EDA_finishers_carreras.ipynb`; el modelo predictivo, en `Modelo_finishers.ipynb`; y el dashboard de Power BI.

De 13 fuentes dispersas a un dataset único de 49.953 filas, en cuatro pasos




El diagrama resume el proceso completo, desde las 13 fuentes originales hasta los tres productos finales del trabajo: el EDA, el modelo predictivo y el dashboard de Power BI.

2. Datos y metodología

En este apartado se describe el proceso completo seguido para construir el dataset final del trabajo: la obtención de los datos brutos a partir de las distintas fuentes, su limpieza y unificación en una tabla común, las decisiones metodológicas más relevantes tomadas durante ese proceso, y la estructura final del dataset resultante, que alimenta tanto el análisis exploratorio como el modelo y el dashboard.

El conjunto de datos final integra 13 fuentes distintas. Doce se obtuvieron mediante scraping de otros tantos portales de resultados deportivos: buscametas, youevent, carreirasgalegas, ccnorte, cursescat, cruzandolameta, cronorunner, cronofinisher, championchip, mychip, sportmaniacs y timingsys. La decimotercera, Iter5, se incorporó directamente a partir de un dataset ya elaborado que recibí por mail. No existe una API común entre portales, así que cada fuente requirió su propio proceso de extracción, con planteamientos distintos según cómo cada organizador publica sus resultados.



Cruzandolameta y timingsys parten de este mismo planteamiento, pero con una complicación añadida para cubrir todos sus eventos. Cruzandolameta reparte los resultados en varios formatos según el evento; uno con campos ya limpios, otro que implica contar filas filtradas por género, uno solo disponible en PDF y eventos sin resultados. Hay que detectar automáticamente cada caso antes de

procesar la carrera. Timingsys, por su parte, combina dos sistemas distintos del mismo proveedor, uno documentado y otro heredado que almacena los resultados como archivos comprimidos, y requirió además recuperar información perdida en eventos con más de una distancia, cruzando un índice histórico por fecha y nombre.

Un segundo conjunto de fuentes no ofrece ninguna API, sino que exige leer directamente las tablas HTML de resultados que publica cada organizador, distinguiendo el género a partir de palabras clave dentro de la propia tabla. Championship sigue este planteamiento. Ccnorte parte del mismo proceso base, pero se detectó un problema de sobreconteo y hubo que corregirlo con un método propio de conteo por posición. Otras fuentes de este grupo, como cursescat, también parten de una lectura HTML directa, aunque en algunos casos el género y el volumen de finishers no se leen de la misma tabla que la distancia de la prueba, lo que exige emparejar ambas fuentes de información.

Un tercer grupo de fuentes solo publica los resultados en documentos PDF, lo que obligó a extraer las tablas de esos documentos e inferir el género a partir de los códigos de categoría de cada participante. Youevent y cronofinisher proponen este reto; youevent combina dos niveles de inferencia (primero la etiqueta del enlace al PDF y, si no es concluyente, el código dentro del propio documento), mientras que cronofinisher tuvo que contemplar hasta cuatro convenciones distintas usadas por los organizadores para indicar el sexo: palabra completa, abreviatura, una única letra final o el sexo indicado solo en el nombre del archivo, aplicando en cada caso el método correspondiente.

Como ya se ha comentado, la fuente restante, Iter5, se recibió ya elaborada en formato csv, por lo que no requirió ningún desarrollo propio de extracción, más allá de adaptarla al esquema común del resto de fuentes ([apartado 2.2](#)).

2.2. Limpieza y unificación de datos

Antes de la unión, cada una de las 13 fuentes pasó por su propio notebook de limpieza (`Limpieza_<fuente>.ipynb`), que adapta los datos crudos de esa fuente al esquema común de 12 columnas. Este proceso incluye, según el caso, renombrar y seleccionar las columnas relevantes, extraer la distancia de la prueba mediante expresiones regulares cuando la fuente no la da como campo propio (por ejemplo, a partir de literales como "10K" o "21,1K" en el nombre de la modalidad), y completar la ubicación cuando la fuente no ofrece comarca o provincia, geocodificando el municipio con Nominatim. También clasifica cada carrera por tipo de modalidad: running, trail, ciclismo, natación, multidisciplina o marcha. Del mismo modo clasifica el público de la prueba: infantil, absoluta/general, máster/veteranos,

élite o equipos. Ambas clasificaciones se hacen mediante reglas por palabras clave, verificadas contra los datos reales de cada fuente y, en los casos ambiguos, resueltas consultando fuentes externas, como calendarios de carreras, en lugar de asumir una categoría al azar. Algunas fuentes exigieron además una reestructuración previa más específica; por ejemplo lter5, que, al recibir ya el fichero csv trabajado, cada carrera llegaba repartida en dos filas (una por sexo) en lugar de en columnas separadas, así que hubo que pivotar la tabla antes de poder aplicar el resto del proceso.

Las fuentes ya limpias se unieron en una única tabla, quedándose solo con las 12 columnas que todas comparten: fuente, nombre de la carrera, fecha, día de la semana, distancia, modalidad, público, finishers hombres, finishers mujeres, municipio, comarca y provincia. Las columnas propias de cada fuente no son comparables entre sí y se descartaron en este paso.

En este mismo notebook de unión se hizo también un primer fix necesario, normalizar la columna `provincia` hasta dejarla reducida exactamente a las 52 provincias oficiales de España, el nivel de normalización que se necesitaba para poder trabajar con ella. Tal como llegaba de cada fuente tenía 75 valores distintos por errores de escritura y de formato. Se redefinió a partir del código numérico oficial del INE (`provincia_ine`), mapeado contra un diccionario canónico de las 52 provincias, lo que transformó esos 75 valores en los 52 oficiales. En las comunidades uniprovinciales el nombre de la provincia y el de la comunidad coinciden, así que la comprobación pensada para el error contrario (una comunidad multiprovincial escrita por error en el campo provincia) las vaciaba también a ellas por error. La solución combinó tres vías, por orden: recuperar la provincia desde el código INE ya resuelto, aplicar alias de municipio verificados a mano y, en último caso, deducirla a partir de la comarca. Con todo ello, la cobertura de provincia pasó de 8.532 filas sin resolver a solo 71 (un 0,15% de las filas con municipio conocido), que ya no son resolubles porque no describen un lugar real o porque el topónimo es ambiguo entre varias provincias. La columna `municipio` recibió un tratamiento parecido, más breve. Se unificaron las grafías distintas de un mismo municipio (124 casos, como "LLEIDA"/"Lleida"), quedándose con la más frecuente, y esa grafía se sustituyó después por el nombre oficial del nomenclátor del IGN/CNIG en las 6.037 filas donde cruzaba directamente con él.

Otro fix relevante fue el de `finisher_desconocido` (participantes cuyo género no especifica la fuente). Al quedarse solo con las columnas comunes, esta información se perdía, y para 294 carreras de una sola fuente (26.436 participantes), además de varias más en otras fuentes, todos los finishers estaban ahí, así que `total_finishers` acababa en 0 o nulo y la carrera entera desaparecía del análisis. Se añadió como columna adicional (siempre al final, porque el Power BI referencia columnas

por posición) y se sumó a `total_finishers`, recuperando 763 filas y más de 266.000 participantes que antes no se contabilizaban.

2.3. Decisiones metodológicas clave

Lo que sí se corrigió siempre fue el centinela `distancia == 0`, que no significa una carrera de 0 km sino que la distancia no se pudo extraer del origen; se convierte en un valor nulo y, cuando el nombre del evento contiene un único patrón de distancia sin ambigüedad, se intenta recuperar desde ahí. Los valores más extremos de participantes y de distancia se revisaron también a mano (top 20 de cada uno) para confirmar que correspondían a eventos reales, como maratones masivos, pruebas de ultrafondo de varios cientos de kilómetros o retos acumulados a lo largo de semanas, y no a errores de scraping. Solo se anula un valor cuando supera un umbral de plausibilidad claramente absurdo, como más de 100.000 finishers en una sola carrera.

Más allá de esta revisión puntual, el tratamiento de outliers propiamente dicho se hizo en un notebook aparte, porque la decisión de qué hacer con un valor extremo depende de para qué se vaya a usar después el dato. No es lo mismo preparar los datos para un modelo basado en árboles de decisión, poco sensible a los valores extremos, que para un dashboard, donde sí distorsionan medias, sumas y escalas de ejes.

Para el modelo predictivo, que se basa en árboles de decisión, los valores extremos de las variables predictoras no se recortan de forma agresiva. Un árbol divide el espacio por umbrales de orden (por ejemplo, si la distancia supera los 21 km), no por la magnitud numérica exacta, así que un valor aislado muy alto no lo distorsiona como sí haría en una regresión lineal. Sin embargo, como este mismo fichero (`DF_TODAS_SIN_OUTLIERS.csv`) también alimenta el dashboard de Power BI, donde los valores extremos sí distorsionan medias, sumas y escalas de ejes, el recorte de valores extremos (limitar `distancia`, `finisher_d` y `finisher_h` al percentil 99 dentro de cada modalidad, una técnica conocida como winsorización) está activado por defecto en `Limpieza_outliers.ipynb`, aunque se ha programado de forma que sea ágil sacar la tabla sin capar o partir directamente de `DF_TODAS_UNION.csv`. Esta decisión tiene una consecuencia real para el modelo, comentada en el [apartado 4.4](#). El propio recorte limita el valor máximo que el modelo puede llegar a predecir.

Otra decisión tomada en `Limpieza_union.ipynb` trata las filas con el total de finishers conocido pero sin desglose por género (1.265 filas, un 3,2% del dataset). En vez de descartarlas, se reparte su `total_finishers` según el porcentaje de mujeres de carreras comparables (misma

tipo_modalidad, publico y anyo, con retroceso a grupos más amplios cuando ese grupo tiene menos de 100 participantes con género conocido), guardando el resultado en columnas nuevas finisher_d_est/finisher_h_est que nunca sobrescriben un dato real. En el 99,3% de los casos se pudo usar el nivel más específico de agrupación. Estas columnas están pensadas para el EDA y el dashboard, donde recuperan ese 3,2% de filas en las estadísticas agregadas; no se usan como variable objetivo del modelo predictivo, ya que un experimento aparte confirmó que añadir las al entrenamiento no cambia las métricas (solo un 2% de las filas de entrenamiento del universo del modelo se ven afectadas).

2.4. Estructura final del dataset

El resultado de todo el proceso anterior es DF_TODAS_SIN_OUTLIERS.csv, el dataset que alimenta tanto el dashboard de Power BI como el modelo predictivo. Ambos usos se unificaron sobre el mismo fichero para no mantener dos limpiezas del centinela de distancia desincronizadas entre sí.

El dataset final tiene 49.953 filas y 34 columnas fijas, 31 originales más tres añadidas al final el 29/9 (finisher_d_est, finisher_h_est y nivel_pct_genero, ver más abajo), sin alterar el orden de las demás porque el Power BI las referencia por posición. Integra las 13 fuentes que llegaron a poder escapearse correctamente. La cobertura de provincia alcanza el 93,0% de las filas, y el cruce con la población del INE cubre el 85,3%. El resto son sobre todo filas donde la fuente original no da una ubicación resoluble a nivel de municipio o provincia.

Esquema final de columnas de DF_TODAS_SIN_OUTLIERS.csv, en el orden real del fichero (el orden importa porque Power BI referencia las columnas por posición):

Columna	Tipo	Descripción
fuelle	texto	Portal de origen de la carrera (una de las 13 fuentes scrapeadas)
nombre_carrera	texto	Nombre del evento
fecha	fecha	Fecha de celebración
dia_semana	texto	Día de la semana
distancia	numérico	Distancia de la prueba, en km
tipo_modalidad	texto	Disciplina (running, trail, ciclismo, etc.)
publico	texto	Categoría de público (Absoluta/General, Infantil, etc.)
finisher_d	numérico	Finishers mujeres (dato real; nulo si el género no se pudo desglosar)
finisher_h	numérico	Finishers hombres (dato real; nulo si el género no se pudo desglosar)
municipio	texto	Municipio de celebración, tal como lo da la fuente

Columna	Tipo	Descripción
comarca	texto	Comarca
provincia	texto	Provincia, tal como la da la fuente
anyo	entero	Año de la edición
mes	entero	Mes de la edición
estacion	texto	Estación del año
total_finishers	numérico	finisher_d + finisher_h + finisher_desconocido
es_finde	booleano	Si la fecha cae en fin de semana
municipio_norm	texto	Municipio normalizado, clave de cruce con el INE
provincia_norm	texto	Provincia normalizada
provincia_ine	numérico	Código de provincia del INE
total_poblacion	numérico	Población total del municipio (cruce INE)
poblacion_h	numérico	Población hombres del municipio
poblacion_d	numérico	Población mujeres del municipio
es_carrera_popular	booleano	Si el nombre del evento sugiere carrera popular
distancia_conocida	booleano	Si la distancia es un dato real o imputado
finisher_desconocido	numérico	Finishers sin género especificado por la fuente
comunidad_autonoma	texto	Comunidad autónoma, tal como la da la fuente
finisher_d_est	numérico	Estimación de finisher_d para filas sin desglose por género (apartado 2.3)
finisher_h_est	numérico	Estimación de finisher_h para filas sin desglose por género (apartado 2.3)
nivel_pct_genero	numérico	Nivel de agrupación usado para estimar finisher_d_est/finisher_h_est
comunidad_autonoma_norm	texto	Comunidad autónoma normalizada
anyo_cruce	entero	Año usado para el cruce de población
superficie_km2	numérico	Superficie del municipio, en km ²
densidad_poblacion	numérico	Densidad de población del municipio

Tabla 1. Esquema de columnas de DF_TODAS_SIN_OUTLIERS.csv, en el orden real del fichero.

3. Análisis exploratorio (EDA)

Antes de entrenar cualquier modelo conviene entender qué patrones esconden los datos. Por eso este apartado explora, sobre el dataset final descrito en el [apartado 2.4](#), la distribución geográfica y temporal de las carreras, la participación por género y su relación con la modalidad y la distancia, y el perfil de los participantes por tipo de público. Estos hallazgos no son solo descriptivos. Varias de las decisiones tomadas en el modelo predictivo del [apartado 4](#) nacen de aquí, y anticipan buena parte de lo que después se verá con más detalle en el dashboard del [apartado 5](#).

3.1. Distribución geográfica

El análisis exploratorio parte del dataset final descrito en el [apartado 2.4](#), con 49.953 filas de datos de participación en carreras. La cobertura geográfica es muy desigual entre provincias, como ya se anticipaba en el [apartado 1.3](#): Valencia (5.803 filas), A Coruña (4.402), Barcelona (3.755), Alicante (2.271) y Lleida (1.859) concentran, juntas, más de un tercio del dataset, mientras que buena parte del interior peninsular apenas tiene presencia. Como se explicó en el [apartado 2.2](#), la columna `provincia` ya está normalizada a las 52 provincias oficiales, así que este ranking refleja de forma fiable qué provincias han aportado más filas, no necesariamente dónde se corre más en España; responde sobre todo a qué portales de cronometraje se han podido scrapear y no a un muestreo representativo del territorio.

La columna `comunidad_autonoma` solo llega directamente en el 16% de las filas (8.016). Es un dato adicional que algunas fuentes proporcionan de forma explícita, casi siempre para comunidades multiprovinciales (Comunidad Valenciana, Galicia, Cataluña, Andalucía...), mientras que en las 9 comunidades uniprovinciales (Madrid, Asturias, Cantabria...) esa misma información ya queda recogida en `provincia`. Por este motivo esta columna no se utiliza en el dashboard.

El cruce con los datos de población del INE cubre el 85,3% de las filas; la mediana de población del municipio donde se celebra una carrera es de 14.652 habitantes, con una cola larga de grandes ciudades que eleva la media hasta 177.381, la mayoría de las carreras populares del dataset ocurren en municipios pequeños o medianos, no en las grandes capitales. La densidad de población, calculada a partir del mismo cruce con el INE, tiene una mediana de 283 habitantes por km².

3.2. Evolución temporal

La serie temporal del dataset arranca de forma anecdótica (una sola fila en 2003) y crece de forma prácticamente ininterrumpida hasta 2018-2019 (en torno a 4.000 filas por año), con una caída clara en 2020 (1.212 filas) coincidiendo con la pandemia, una recuperación rápida en 2021-2022 y un máximo en 2023 (6.364 filas). Desde entonces el número de filas baja, hasta 2.561 en 2026. Gran parte de ese descenso final corresponde a 2026, el año en curso en el momento de este análisis, con datos todavía incompletos, y no a una caída real de la actividad.

El calendario de carreras está muy concentrado en fin de semana. Cerca del 90% de las filas caen en sábado o domingo (17.302 y 27.607 filas respectivamente), frente a apenas un 10% entre semana. Por estación, el otoño concentra el mayor volumen de participación (2.810.871 finishers entre hombres y

mujeres), seguido de la primavera, mientras que el invierno y sobre todo el verano son los periodos con menos actividad, un patrón coherente con el calendario habitual de las carreras populares en España.

El hallazgo más relevante de esta sección, de cara al modelo predictivo, es la fuerza del historial propio de cada carrera. Identificando ediciones consecutivas de la misma prueba (mismo nombre base, sin el ordinal ni el año, dentro de la misma fuente), la correlación entre los finishers de un año y los del año anterior es de 0,90 sobre 8.013 pares de ediciones consecutivas disponibles. Es, con diferencia, la señal más fuerte de todo el análisis exploratorio, muy por encima de cualquier combinación de modalidad, distancia o población. Tiene sentido. El tamaño de una carrera responde a factores que apenas cambian de un año a otro (su reputación, la comunidad de corredores que la sigue, la localidad donde se celebra, su fecha en el calendario), así que cada edición tiende a atraer a un público similar al de la anterior; un límite estricto de plazas solo puede explicar el patrón en la minoría de carreras masivas con inscripción agotada, no en el conjunto del dataset. Esto se tiene en cuenta en el modelo predictivo.




Figura 2. Evolución anual del número de filas del dataset (2003-2026). Se aprecia la caída marcada en 2020 y el pico en 2023, seguido de un descenso hasta 2026 (año parcial).

3.3. Participación por género

Uno de los objetivos específicos de este TFM, como se comentó en el [apartado 1.1](#), es comprobar si la participación femenina disminuye en las modalidades y distancias más exigentes. Por modalidad, ninguna disciplina alcanza la paridad. La marcha es la más equilibrada (37,0% de mujeres) y el ciclismo y btt la menos (5,7%), con el running (35,5% en road running, 25,8% en trail running) y la natación (31,5%)

en un punto intermedio. El propio running muestra ya una brecha entre su variante de carretera y la de montaña, que es la modalidad físicamente más exigente de las mayoritarias.

El patrón se confirma, y de forma mucho más marcada, al mirar la distancia. El porcentaje de mujeres cae de forma prácticamente monótona a medida que crece el recorrido, desde el 50,0% en las pruebas de hasta 5 km hasta el 37,4% entre 5 y 10 km, el 22,2% entre 10 y 21 km, el 15,1% entre 21 y 42 km, el 10,9% entre 42 y 100 km y solo el 6,2% por encima de 100 km. En las distancias de ultrafondo la brecha de género es notoriamente superior que en las carreras populares más cortas; la evidencia más clara de que la respuesta a la pregunta de partida es afirmativa.

El tipo de público también influye. La categoría Infantil es la más paritaria (43,3% de mujeres) y Elite la menos (21,1%), con Absoluta/General (el grueso del dataset) en el 31,3%. Esta diferencia refuerza la lectura anterior, ya que cuanto más competitiva o exigente es la categoría, menor es la presencia femenina.

En el tiempo, la participación femenina crece algo más rápido que la masculina, aunque desde una base mucho más baja. El porcentaje de mujeres solo sube del 29% al 32% en once años. La participación también es algo más equilibrada en municipios grandes (39,1% de mujeres en el cuartil de población más alto, frente al 22,0-22,7% en los dos cuartiles más pequeños) y, sobre todo, en las carreras identificadas como populares por su nombre (47,0% de mujeres, frente al 25,4% del resto). El formato abierto y participativo de las carreras populares parece atraer proporcionalmente mucha más participación femenina que las pruebas de corte más competitivo.

La distribución geográfica también varía por género, entre las provincias con más volumen de participación, el porcentaje de mujeres oscila entre el 23,2% (Castellón) y el 53,1% (Barcelona), lo que confirma que tener mucha participación total no implica tener una participación equilibrada entre hombres y mujeres.




Figura 3. Finishers por género y tramo de distancia (valores absolutos). La proporción de mujeres respecto al total cae de forma casi monótona a medida que aumenta la distancia.

3.4. Modalidades y perfil de participantes

El dataset cubre las disciplinas objeto de este TFM (running, ciclismo, natación, marcha y modalidades multideporte como el triatlón), aunque de forma muy desigual ya que Road running (28.756 filas) y Trail running (9.065) suponen juntas el 76% del total. Esta concentración en el running no es solo un sesgo introducido en el scraping, sino que también refleja la propia oferta de carreras populares en España.

La distancia solo se pudo determinar en el 50% de las filas (24.942 de 49.953). El resto queda en un valor nulo porque la fuente no la proporciona, algo frecuente en categorías desglosadas solo por edad o género. Entre las filas con distancia conocida, la mediana es de 8,1 km, con picos claros en las distancias más habituales de las carreras populares (5, 10, 21 y 42 km) y una cola larga de pruebas de ultrafondo que llega hasta los 934 km (marchas cicloturistas y ultra-trails, ya revisadas en el [apartado 2.3](#) como parte del tratamiento de outliers).

En cuanto al perfil de participantes propiamente dicho, la variable publico distingue precisamente estas categorías. Por tipo de público, Absoluta/General concentra el 70,7% de las filas (35.327), no porque las categorías infantiles, de veteranos o de élite sean residuales en la realidad, sino porque varias fuentes no desglosan la participación por edad y toda esa participación cae en la categoría genérica. Infantil es la segunda categoría en volumen (12.611 filas, 25,2%). Aparte de publico, el

dataset incluye otro campo, `es_carrera_popular`, que no es una categoría más de público sino una variable independiente que marca el 25,4% de las filas a partir de patrones en el nombre del evento (palabras como "popular", "solidaria" o "San Silvestre"). Es un índice aproximado basado en texto, no una categoría explícita de ninguna fuente. Se creó para poder analizar de forma directa el objeto central de este TFM, la participación en carreras populares. Como se ha visto en el [apartado 3.3](#), es también el subconjunto con la participación femenina más equilibrada de todo el dataset.

Antes de pasar al modelo, conviene destacar un resultado de la matriz de correlación completa entre variables. Ninguna variable individual correlaciona con fuerza con `finisher_d/finisher_h`; público y la población del municipio son, por separado, las que más pesan, un patrón que confirma después el modelo final ([apartado 4.3](#)).




Figura 4. Matriz de correlación de Pearson entre las variables numéricas y categóricas codificadas del dataset. Las correlaciones más fuertes son las esperables por construcción (`finisher_d/finisher_h` con

total_finishers, 0,83 y 0,79; *dia_semana_num* con *es_finde*, 0,80; *total_poblacion* con *densidad_poblacion*, 0,55); entre *finisher_d* y *finisher_h* la correlación es mucho más moderada (0,32), coherente con la brecha de género descrita en el [apartado 3.3](#). El resto de variables predictoras apenas correlacionan entre sí, lo que descarta problemas graves de multicolinealidad de cara al modelo del capítulo 4.




Figura 5. Distribución de filas por *tipo_modalidad*. Road running y trail running concentran la gran mayoría de las filas, muy por delante del resto de modalidades.




Figura 6. Distribución de filas por *publico*.

4. Modelado predictivo

El análisis exploratorio del [apartado 3](#) deja patrones claros, pero no resuelve la pregunta que motivó este trabajo. ¿Cuántos finishers puede tener una carrera que todavía no tiene historial propio? Este apartado aborda esa pregunta con un modelo predictivo, motivado por el escenario planteado en el [apartado 1.1](#): se plantea el problema y las variables utilizadas, se explican los algoritmos y el proceso de evaluación, se comparan los resultados de dos versiones del modelo y se discuten sus principales limitaciones.

4.1. Planteamiento y variables

El modelo predictivo busca estimar `finisher_d` y `finisher_h`, los finishers mujer y hombre, de una categoría de carrera a partir de sus características. Siguiendo la conclusión del [apartado 3.3](#), es decir, que la participación femenina se comporta de forma muy distinta según distancia y modalidad, se entrenan dos modelos independientes en lugar de uno multi-output, uno por objetivo, de forma que cada uno pueda ajustarse a su propia dinámica.

El modelo parte de `DF_TODAS_SIN_OUTLIERS.csv`. El modelo se restringe además a las carreras de `tipo_modalidad` `Road running` y `Trail running` y `publico` `Absoluta/General`. Así pues, quedan un total de 25.6k filas (el 51,3% del dataset). Es el segmento más grande y homogéneo del dataset ([apartado 3.4](#)) y también el de mayor interés para el objetivo del trabajo. Este filtrage se aplica antes de calcular población, distancia, historial o comparables, para que todos esos cálculos se hagan ya sobre el universo final del modelo.

Antes de fijar este filtro se probó también restringir el universo, dentro de este mismo segmento, a las filas con `es_carrera_popular` igual a 1 (es decir, solo carreras populares según patrones en el nombre). El resultado no mejoraba de forma apreciable y restringía mucho mas el dataset, así que se descartó y el modelo final mantiene todo el segmento `running/trail` de público general, sea o no detectado como carrera popular por el nombre.

El reparto entre entrenamiento y prueba es temporal, nunca aleatorio por fila. Como se vio en el [apartado 3.2](#), la correlación entre los finishers de una carrera un año y los del año anterior es de 0,90, así que partir filas al azar dejaría ediciones consecutivas de la misma carrera repartidas entre entrenamiento y prueba, y el modelo parecería mucho mejor de lo que realmente es. Tras descartar las filas sin `finisher_d/finisher_h` reales (categorías nunca capturadas, no carreras de cero personas)

quedan 21.849 filas para modelar. Se entrena con los años hasta 2024 (18.271 filas, 83,6%) y se evalúa con 2025 y 2026 (3.578 filas, 16,4%, 2.429 de 2025 y 1.149 de 2026, este último todavía parcial).

Las variables utilizadas son de tres tipos: numéricas (`distancia`, `anyo`, población total del municipio, el historial de la propia carrera y una estimación por carreras comparables cuando no existe historial, y el número de carreras cercanas en un radio de 40 km), booleanas que indican la fiabilidad de cada dato (`distancia_conocida`, `poblacion_conocida`, `tiene_historial`, `ubicacion_precisa`) y categóricas codificadas mediante one-hot (`tipo_modalidad`, `estacion`, `provincia`); `publico` deja de usarse como feature porque, tras el filtro anterior, queda constante.

El cruce con la población del INE cubre el 83,3% de las filas del universo filtrado (21.359 de 25.635). El resto se imputa con la mediana global (13.217 habitantes), conservando el booleano `poblacion_conocida` para que el árbol pueda distinguir un dato real de uno imputado. La distancia, cuando falta, se imputa con la mediana dentro de cada `tipo_modalidad`, porque la escala típica es muy distinta entre disciplinas.

Para la señal de carreras cercanas se cruzan las coordenadas de 8.132 municipios de España verificadas contra el INE, lo que cubre el 82,6% de las filas con una coordenada real del propio municipio (una mejora notable sobre una versión anterior basada solo en cachés de geocodificación sueltas de cada fuente, que apenas llegaba al 31,9%); el resto recurre al centroide de la provincia o, en último caso, al centroide de España. Con esas coordenadas, y construyendo el árbol de vecinos solo con años de entrenamiento (para no filtrar información del conjunto de prueba), se cuenta cuántas otras carreras del mismo universo hay en un radio de 40 km alrededor de cada carrera, como aproximación a la "cultura runner" de cada zona a una escala más fina que la provincia.

4.2. Algoritmos y evaluación

El algoritmo elegido es un `RandomForestRegressor` de `scikit-learn`, uno por objetivo. Antes de entrenar nada se calcula un baseline ("este año será como el anterior", es decir, el valor de la edición anterior cuando existe, o la mediana de entrenamiento si no) para comprobar que el modelo aporta valor real por encima de la señal más simple posible. Los hiperparámetros se ajustan con una validación walk-forward año a año (entrenando solo con los años anteriores a cada año de validación, dentro del propio conjunto de entrenamiento), no con una validación cruzada aleatoria, por el mismo motivo que el split final es temporal.

Se evalúa con cuatro métricas: MAE y RMSE (en número de finishers), R^2 y el error relativo mediano. Esta última métrica se incorporó porque el MAE en escala absoluta está sesgado por el tamaño de la carrera (una maratón de 5.000 finishers pesa mucho más en el MAE que una carrera de pueblo de 50 personas, aunque el modelo acierte mejor esta última en términos proporcionales).

Concretamente, la búsqueda usa como pliegues de validación los 5 años más recientes con datos suficientes (2020 a 2024, entrenando cada pliegue solo con los años anteriores a él). El resultado actual es `finisher_d` con `n_estimators=150`, `max_depth=None`, `min_samples_leaf=2` (MAE walk-forward 44,0), y `finisher_h` con `n_estimators=300`, `max_depth=None`, `min_samples_leaf=2` (MAE walk-forward 80,4).

El modelo se desarrolló en dos versiones. La versión inicial (v1) incluye como features el historial de la propia carrera (`finisher_*_anterior`) y, para las carreras sin historial, una estimación por carreras comparables (misma modalidad, público, provincia y tramo de distancia, con retroceso a grupos más amplios cuando hay pocas muestras). Al revisar esta primera versión se encontraron dos problemas de fondo, no solo de ajuste fino: primero, un bug real en las filas con `finisher_d` y `finisher_h` a la vez en cero, donde en el 100% de los casos el género en realidad no se había podido desglosar (`finisher_desconocido` mayor que cero) en lugar de tratarse de una carrera de cero participantes; segundo, que la importancia de variables por permutación mostraba que, sin las variables de historial, el modelo generalizaba igual o mejor, señal de que su versión inicial (con mucho peso en la estimación por comparables) aportaba más ruido que señal pese a la fuerte correlación de 0,90 vista en el [apartado 3.2](#).

La versión recomendada (v2) corrige ambos problemas. Convierte a nulo el falso cero cuando `finisher_desconocido` es mayor que cero (448 filas en el universo actual), y elimina del modelo el historial y los comparables, sustituyéndolos por `carreras_historicas_municipio` (el número de carreras celebradas anteriormente en ese municipio, contando solo años de entrenamiento), una señal más simple de "cultura runner" local que sí demostró aportar valor real. Los resultados de ambas versiones se comparan en el [apartado 4.3](#).

4.3. Resultados

Como referencia, el baseline ingenuo (el valor de la edición anterior, o la mediana si no existe) obtiene un R^2 negativo en el conjunto de prueba (-0,043 en `finisher_d`, -0,137 en `finisher_h`). Cualquiera de las dos versiones del random forest mejora claramente esta referencia. La tabla siguiente resume el

resultado de ambas versiones sobre el conjunto de prueba (2025-2026), ya con el universo restringido a running/trail y público general del [apartado 4.1](#).

Este resultado negativo puede sorprender dada la correlación de 0,90 vista en el [apartado 3.2](#), pero tiene una explicación sencilla. El baseline solo puede aprovechar el valor de la edición anterior en el 29,7% de filas que tienen historial real; en el resto recurre a la mediana de entrenamiento, un predictor pobre que arrastra el resultado agregado a la baja. Por eso el valor real de los modelos no debe juzgarse por esta cifra global, sino separando el rendimiento entre carreras con y sin historial propio, como se hace más abajo. Es precisamente en las carreras sin historial, el caso de uso real que motiva este trabajo ([apartado 1.1](#)), donde se pone a prueba si las variables estructurales (distancia, población, época, geografía) aportan algo por sí solas, más allá de repetir lo que ya se sabía de la propia carrera.

Modelo	Objetivo	MAE	RMSE	R ²	Error relativo mediano
v1	finisher_d	55,2	135,3	0,319	57,0%
v1	finisher_h	110,8	261,2	0,330	53,1%
v2	finisher_d	56,7	128,0	0,391	52,2%
v2	finisher_h	99,8	224,8	0,504	44,3%

Tabla 2. Resultados de los modelos v1 y v2 (MAE, RMSE, R² y error relativo mediano) sobre el conjunto de prueba (2025-2026).

La versión v2 mejora a la v1 en los dos objetivos, y de forma especialmente clara en `finisher_h` (R² de 0,330 a 0,504, error relativo de 53,1% a 44,3%). El MAE de `finisher_d` sube ligeramente en la v2 (de 55,2 a 56,7), pero es coherente con lo señalado en el [apartado 4.2](#). El MAE en crudo penaliza más las carreras grandes, y tanto el R² como el error relativo (las dos métricas menos sesgadas por el tamaño) mejoran en ambos objetivos.

En el modelo v2, sin el historial dominando el reparto de importancia, `total_poblacion` pasa a ser la variable más determinante en los dos objetivos (34,0% de la importancia agregada en `finisher_d`, 26,3% en `finisher_h`), seguida de `distancia` (14,8%/19,9%), `provincia` (12,1%/17,5%), `anyo` (10,4%/10,7%) y `estacion` (10,3%/9,2%). `carreras_radio_40km`, la señal geográfica, aporta un 6-8% de la importancia en ambos modelos, y `carreras_historicas_municipio` un 3,5-4,1% adicional, valores modestos pero reales. `tipo_modalidad` aporta poco por sí sola (menos del 1%), probablemente porque su información ya queda parcialmente capturada por `distancia` (cada disciplina tiene un rango de distancias típico).

Importancia de variables (modelo v2)

total_poblacion concentra el 34,0% (finisher_d) y el 26,3% (finisher_h) de la importancia total, muy por delante del resto

■ finisher_d ■ finisher_h




Figura 7. Importancia de variables por permutación del modelo v2, agregada por variable original, para *finisher_d* y *finisher_h*.

Un desglose adicional del modelo v1 confirma dónde está el reto real. Separando el conjunto de prueba entre carreras con historial de la edición anterior y carreras sin él, el modelo acierta mucho mejor en las primeras (R^2 de 0,529 en *finisher_d* y 0,498 en *finisher_h*) que en las segundas (R^2 de solo 0,099 y 0,191). Predecir una carrera completamente nueva, precisamente el caso de uso que motivó este TFM ([apartado 1.1](#)), sigue siendo el escenario más difícil y el que más margen de mejora tiene.

El dataset con el que se entrena y evalúa el modelo es ya `DF_TODAS_SIN_OUTLIERS.csv`, la versión final descrita en el [apartado 2.4](#).

Más allá de las métricas agregadas, el notebook incluye un análisis de dispersión predicción-realidad (escala logarítmica) para los cuatro modelos, junto con los casos concretos donde el modelo v2 más acierta y más falla sobre el conjunto de test. Las predicciones más precisas corresponden a carreras pequeñas o medianas con historial reciente (por ejemplo, la 15a edición del Trail La Riera de 2025, con 30 finishers mujeres y 113 hombres reales, predicha en 30,0 y 114,0). Las cinco predicciones más alejadas de la realidad, en cambio, comparten un patrón claro. Son ediciones de San Silvestre y otras

carreras masivas de road running (1.367,16 finishers mujeres y 2.708,8 hombres reales en varias de ellas) donde el modelo predice muy por debajo, entre 123 y 330 personas.




Figura 8. Dispersión predicción vs realidad (escala $\log(1+x)$) para los cuatro modelos (`v1/v2` × `finisher_d/finisher_h`) sobre el conjunto de test; la línea discontinua marca `predicción = realidad`.

Esta desviación no es un fallo de ajuste del modelo, sino una consecuencia directa del recorte de valores extremos aplicado en `Limpieza_outliers.ipynb` ([apartado 2.3](#)). Al recortar `finisher_d` y `finisher_h` al percentil 99 de su modalidad, el valor real de esas carreras masivas queda capado exactamente en esas cifras (1.367,16 y 2.708,8) antes incluso de entrenar el modelo, que nunca observa en el conjunto de entrenamiento un valor tan alto y por tanto no puede aprender a predecirlo. Es una limitación heredada de una decisión metodológica tomada pensando en el dashboard, no en el modelo, y se retoma en el [apartado 4.4](#).

Trasladado al escenario concreto que motivó este TFM, estimar de antemano cuántos finishers tendría una carrera nueva antes de organizarla, estos resultados indican que el modelo v2 ofrece hoy una orientación razonable pero con un margen de error todavía amplio, un error relativo mediano del 52,2% en `finisher_d` y del 44,3% en `finisher_h`, que es aún mayor en el caso más difícil y más relevante para ese escenario, una carrera sin historial previo. En la práctica, esto lo convierte en una herramienta útil para obtener una primera estimación orientativa, no en una predicción exacta con la que dimensionar una carrera con precisión.

4.4. Limitaciones

Una parte de las variables más importantes del modelo son, en realidad, valores imputados y no observaciones reales. La población del municipio se imputa en el 16,7% de las filas del universo filtrado (4.276 de 25.635) con la mediana global, y la distancia se imputa con la mediana de cada modalidad en las filas donde faltaba. Antes de interpretar su importancia como una relación causal conviene tener en cuenta que una parte de esos valores son "rellenos", no observaciones.

La señal de carreras cercanas (`carreras_radio_40km`) mejoró de forma notable respecto a una primera versión (del 31,9% de cobertura real de coordenadas al 82,6% actual, gracias al cruce con el dataset de municipios verificado contra el INE), pero sigue sin ser del 100%. En torno a un 17% de las filas recurre al centroide de la provincia o de España en lugar de a la ubicación real del municipio, lo que diluye la precisión de esta variable justo en las zonas con menos carreras geocodificadas.

El modelo solo cubre el 51,3% del dataset final (carreras de running y trail para público general, [apartado 4.1](#)). Sus resultados no son extrapolables sin más a otras modalidades (ciclismo, natación, marcha) ni a otras categorías de público (infantil, veteranos, élite, equipos), que quedarían pendientes de un modelo específico si se quisieran incluir.

El techo que introduce el recorte de valores extremos del [apartado 2.3](#) (percentil 99 de `finisher_d/finisher_h` por modalidad) limita además el valor máximo que el modelo puede llegar a predecir. Las carreras más masivas del dataset (grandes San Silvestres, con miles de finishers reales) quedan capadas ya en el propio dataset de entrenamiento, así que el modelo nunca puede acercarse a su cifra real por encima de ese límite, como se ve en el [apartado 4.3](#).

Solo el 29,7% de las filas del universo del modelo tiene historial real de una edición anterior; el resto depende de la estimación por comparables (en la v1) o directamente no la utiliza (en la v2), y es precisamente en las carreras sin historial donde el modelo peor funciona ([apartado 4.3](#)). El notebook

`Modelo_finishers.ipynb` ya separa el historial real del estimado por comparables en variables distintas (antes se mezclaban en la misma columna). El efecto en las métricas fue prácticamente nulo, porque el modelo ya distinguía ambas señales a través de la variable `tiene_historial`. Queda pendiente repetir este análisis cuando se integren las fuentes de datos que todavía faltan en el dataset.

5. Dashboard (Power BI)

En este apartado se describe el dashboard de Power BI construido para comunicar los resultados de este trabajo: su modelo de datos, un recorrido por sus páginas y las dificultades encontradas en el proceso. A fecha de este documento el dashboard está construido en Power BI, con capturas verificadas de sus cinco páginas.

5.1. Modelo de datos

El modelo de datos del dashboard sigue un esquema en estrella. En el centro, la tabla de hechos `Hechos_Carreras` reúne una fila por carrera con sus variables de finishers, distancia, modalidad, público y fecha.


Alrededor se relacionan, en una relación de uno a muchos, tres dimensiones: `Dim_Geografia`, que centraliza municipio y provincia y es la que permite el cruce con los datos de población del INE a través de `municipio_norm`, el mismo campo normalizado que ya se usa en el análisis de Python ([apartado 2.2](#)); `Dim_Fecha`, con los atributos de calendario derivados de la fecha de cada carrera (año, mes, estación, día de la semana, fin de semana); y `Dim_Fuente`, que identifica la fuente de cronometraje de origen de cada fila.

5.2. Recorrido por las páginas


El dashboard se organiza en cinco páginas, cada una con su titular y su visualización protagonista. Seis segmentadores (año, mes, provincia, modalidad, público y fuente) están disponibles en el panel izquierdo de todas las páginas y sincronizados entre ellas, de modo que aplicar un filtro en una página lo aplica también al resto:

Visión general. Reúne las cifras clave del dataset completo, con el número total de carreras, promedio de finishers por carrera y total de finishers, junto con un medidor del porcentaje de mujeres. El gráfico principal combina barras apiladas (finishers medios por género, hombres y mujeres) con una línea (% de


mujeres) a lo largo de los años, y dos gráficos de anillo desglosan la distribución por modalidad y por tipo de público.




Geografía. Muestra la distribución por provincia: KPI de provincias con datos, porcentaje de carreras localizadas y municipios con datos, un mapa coroplético de España con los finishers por 1.000 habitantes de cada provincia, un gráfico combinado de barras (finishers por 1.000 habitantes) y línea (promedio de finishers) según el tamaño del municipio (pequeño, mediano, muy grande, grande), y un gráfico de barras horizontales con las provincias con más finishers por 1.000 habitantes.




Modalidad y público. Desglosa el reparto por tipo de modalidad y de público, con un mapa de árbol con la distribución total de finishers por modalidad, donde road running y trail running dominan con claridad; barras apiladas del promedio de finishers por público y modalidad; y un diagrama de dispersión del promedio de finishers por carrera frente a la distancia media, en escala logarítmica y coloreado por tipo de público.



Estacionalidad. Recoge la evolución anual, el día de la semana y la estación del año, con una tabla en forma de mapa de calor con la distribución mensual de finishers por año, tarjetas con el mes de más y de menos finishers, un gráfico de líneas con la evolución de finishers mes a mes, una línea por año, un gráfico de anillo entre semana/fin de semana y barras apiladas de finishers por estación del año y género.



Evolución de la participación femenina . Analiza el patrón de género por modalidad, distancia y en el tiempo, con un indicador de variación interanual del porcentaje de mujeres respecto al mismo mes del año anterior, una tabla con el porcentaje de mujeres por modalidad, un gráfico de área con el porcentaje de mujeres por tramo de distancia, y un gráfico de líneas con la evolución mensual del porcentaje de mujeres, una línea por año, y dos gráficos de barras horizontales con el ranking provincial de mayor y de menor paridad de género.



5.3. Dificultades encontradas en el proceso

La página de Geografía presentó una dificultad con los KPI de cobertura del cruce con el INE (población, `municipio_norm`). `ISBLANK()` marcaba como vacías celdas que sí tenían valor. La causa era que Power Query convierte de forma silenciosa los valores nulos del CSV en cadenas de texto vacías en lugar de `BLANK()` real, lo que rompe la lógica habitual de detección de nulos en DAX; el análisis en Python confirmó que existían nulos reales (en torno al 14,7% en población total y al 6,9% en `municipio_norm`). Se solucionó sustituyendo `ISBLANK()` por `TRIM(column & "") <> ""`, que trata igual una cadena vacía y un `BLANK()` real.

6. Conclusiones

6.1. Principales hallazgos

El dataset final reúne 49.953 filas de 13 fuentes de cronometraje, con una cobertura geográfica muy desigual. Las cinco provincias con más filas (Valencia, A Coruña, Barcelona, Alicante y Lleida) concentran juntas más de un tercio del total, un reflejo de qué portales se pudieron scrapear y no de dónde se corre más en España. Esta limitación conviene tenerla presente al leer el resto de hallazgos, que son más representativos de esas zonas que del conjunto del país.

La pregunta que motivó este trabajo, hasta qué punto los hombres siguen monopolizando las modalidades y distancias más exigentes ([apartado 1.1](#)), tiene una respuesta clara en los datos. La participación femenina cae de forma prácticamente monótona con la distancia, del 50,0% en pruebas de hasta 5 km al 6,2% en las de más de 100 km, y es sistemáticamente más alta en las carreras identificadas como populares (47,0% frente al 25,4% del resto). No es solo una cuestión de volumen, ya que cuanto más exigente la prueba, más autoseleccionada parece la presencia femenina, lo que apunta a barreras de entrada (tiempo de entrenamiento, percepción de riesgo, cultura del deporte de resistencia) que pesan más cuanto mayor es la distancia.

El hallazgo más fuerte del análisis exploratorio es el historial propio de cada carrera. La correlación entre los finishers de una edición y los de la anterior es de 0,90, muy por delante de variables como la población del municipio o la distancia. Esto admite una doble lectura: confirma que el tamaño de una carrera es, sobre todo, una propiedad estable de la propia carrera y no tanto del contexto en el que se celebra, pero deja también en evidencia la limitación central del modelo, que funciona bien para carreras consolidadas y es precisamente poco útil para el caso que motivó este trabajo, estimar el tamaño de una carrera sin ediciones previas. El modelo recomendado (v2) mejora claramente al baseline ingenuo, con un error relativo mediano del 52,2% en finisher_d y del 44,3% en finisher_h, una orientación razonable pero con margen de error todavía amplio, explicado en buena parte por ese desequilibrio entre carreras con y sin historial. El dashboard de Power BI traduce estos hallazgos a un formato consultable, con capturas verificadas de sus cinco páginas.

6.2. Limitaciones del trabajo

Más allá de las limitaciones ya detalladas en el [apartado 4.4](#) (variables imputadas, cobertura parcial de la señal geográfica, el techo que introduce el recorte de valores extremos, y un modelo restringido al 51,3% del dataset), el trabajo tiene limitaciones de alcance más generales. El modelo predictivo solo cubre running y trail para público general; el resto de modalidades y categorías de público quedarían pendientes de un modelo específico. Se intentó integrar otras fuentes de datos adicionales, sin éxito, ya que en muchos casos resultaba muy complicado extraer las filas de finishers por sexo y/o los totales.

6.3. Líneas futuras

Como líneas futuras quedan, en el modelo predictivo, integrar las fuentes de datos que todavía faltan, y valorar extender el modelo a otras modalidades (ciclismo, natación, marcha) y categorías de público

(infantil, veteranos, élite, equipos) más allá del running y trail para público general al que se limita la versión actual.

Declaración sobre el uso de inteligencia artificial

Este trabajo ha contado con el apoyo de herramientas de inteligencia artificial (Claude, de Anthropic) en dos frentes: como asistencia en la redacción, edición y formato de esta memoria, y como apoyo puntual en la escritura, depuración y revisión del código Python de los notebooks de scraping, limpieza de datos y modelado. El análisis, las decisiones metodológicas y las conclusiones del trabajo son responsabilidad de la autora.

Bibliografía y fuentes

Fuentes de datos (13 portales de cronometraje, obtenidos mediante scraping salvo Iter5): buscametas, youevent, carreirasgalegas, ccnorte, cursescat, cruzandolameta, cronorunner, cronofinisher, championship, mychip, sportmaniacs y timingsys (scraping); Iter5, incorporada a partir de un dataset ya elaborado recibido directamente de la fuente.

[Instituto Nacional de Estadística \(INE\)](#). Cifras oficiales de población por municipio, usadas para el cruce demográfico descrito en el [apartado 2.1](#).

[Nominatim](#) / [OpenStreetMap](#). Servicio de geocodificación usado para completar la ubicación de las carreras cuando la fuente original no aporta comarca o provincia ([apartado 2.1](#)).

McKinney, W. (2010). Data structures for statistical computing in Python. [Proceedings of the 9th Python in Science Conference](#), 56-61.

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. [Journal of Machine Learning Research](#), 12, 2825-2830.

[Microsoft Power BI Desktop](#), usado para la construcción del dashboard descrito en el [apartado 5](#).